UNIVERSIDAD EAFIT

INGENIERÍA DE SISTEMAS

TRAYECTORIA EN INGENIERÍA DE DATOS

DOCUMENTO DE DEFINICIÓN DEL PROYECTO Y ENTENDIMIENTO DEL DOMINIO

Asignatura: SI4002 - Proyecto de Ingeniería de Datos

Entregable: Fase 1 (Sprint 0)

Profesor: Jose Fabio Jaramillo Castro (jfjaramilc@eafit.edu.co)

Semestre Académico: 2026-2

Descripción del documento:

Este documento propone el formato detallado del entregable de la Fase 1.

Este documento no es solo un requisito académico, sino el contrato técnico y estratégico del proyecto de Ingeniería de datos con el curso, el profesor y la evaluación.

Objetivos del documento:

- Realizar la descripción detallada del caso de negocio (simulado o proveniente de un entorno empresarial real), estableciendo el contexto en el que los datos generan valor, las necesidades analiticas y de gestión y gobernanza de datos.
- Definir con rigor técnico y estratégico el problema a resolver, conectando las necesidades analíticas de los usuarios con los retos de infraestructura subyacentes.
- Establecer el alcance del proyecto.
- Identificar las fuentes de datos operacionales y externas, y el reto principal de como las va obtener o generar mediante datos sinteticos.
- Definir la metodología de desarrollo mediante un marco general de 8 fases de acuerdo a la metodología sugerida para el curso
- Disponer de un buen marco de referencia, marco teórico y sustento para proponer este caso de estudio

El proyecto debe integrar de manera transversal los conocimientos de los tres cursos de la trayectoria: (1) Sistemas Intensivos en Datos, (2) Bases de Datos Avanzadas y (3) Gestión y Gobernanza de Datos.

1. Información General del Proyecto y Equipo

Nombre del Proyecto:	Sistema de Datos Multicloud y Lakehouse en Tiempo Real para Recomendación de Productos y Analítica de Negocio en E-Commerce
Empresa / Caso de Estudio:	Iniciativa académica / Caso simulado de e-commerce (Integración de eventos de comportamiento de usuarios en navegación web y datos transaccionales de ventas)
Semestre Académico:	2026-2
Fecha de Entrega:	30 de julio (Semana 3)

1.1 Conformación del Equipo de Trabajo

Nombre Completo	Correo EAFIT	Correo Gmail	Rol Principal Asignado	Responsabilidades Clave en el Proyecto
Sebastián Castaño	scastanoa@eafit.edu.co	sebastian.castano24@gmail.com	Ingeniero de Pipelines / Big Data	Diseño e implementación de los pipelines de procesamiento batch y streaming. Configuración de los procesos de ingesta desde las diferentes fuentes, implementación del procesamiento con AWS Glue, gestión del almacenamiento de eventos en Amazon S3, procesamiento y organización de datos con Apache Iceberg y preparación de los datos para su consumo analítico en BigQuery.
David Restrepo	drestrepoa@eafit.edu.co	drestrepoa2004@gmail.com	Arquitecto de Datos / Cloud	Diseño de la arquitectura multicloud del proyecto y definición de la interacción entre los servicios de GCP y AWS. Selección y

				configuración de servicios como Google Pub/Sub, Amazon S3, AWS Glue, DynamoDB e Iceberg. Diseño de las integraciones entre nubes y establecimiento de los componentes necesarios para garantizar una arquitectura escalable y desacoplada.
Juan José Botero García	jjboterog@eafit.edu.co	juanjosebg2@gmail.com	Ingeniero de Datos / BI	Diseño de los modelos de datos analíticos y preparación de la información para su explotación. Integración de BigQuery con Power BI para la construcción de dashboards y reportes, definición de indicadores y métricas de negocio y desarrollo de visualizaciones para el análisis histórico y consolidado.

2. Planteamiento del Problema y Contexto de Negocio

La organización es una empresa dedicada a la venta de productos a través de una plataforma digital. Esta genera grandes volúmenes de información que proviene de diferentes fuentes. Por un lado, están los datos transaccionales asociados a las operaciones del negocio: clientes, productos, pagos, pedidos e inventario. Por otro lado, la interacción de los usuarios con la página está generando constantemente eventos de comportamiento como búsquedas, clics, visualizaciones, adiciones y eliminaciones de productos del carrito y los procesos de compra.

Actualmente, la organización enfrenta el reto de aprovechar de manera efectiva estos diferentes tipos de información para apoyar la toma de decisiones. Los datos transaccionales permiten conocer el estado y comportamiento histórico del negocio, mientras que los eventos contienen información valiosa sobre los intereses y comportamientos de los usuarios dentro de la plataforma. No aprovechar estos datos reduce considerablemente el crecimiento del e-commerce, ya que esto se convierte en oportunidades de venta perdidas, decisiones de inventario menos precisas, estrategias de marketing no tan efectivas y una menor capacidad para responder rápidamente a los cambios en el comportamiento de los consumidores.

Por esta razón, se plantea el desarrollo de una plataforma de ingeniería de datos capaz de procesar de manera diferenciada tanto los datos transaccionales generados por los sistemas operacionales como los eventos de interacción de los usuarios. La solución busca proporcionar una arquitectura de datos analítica que permita integrar la información histórica y transaccional con las interacciones de los usuarios, facilitando la construcción y análisis que apoyen la toma de decisiones relacionadas con ventas, comportamiento de clientes, productos e inventario.

2.1 Contexto Organizacional y Descripción del Negocio

La organización objeto del proyecto es una empresa de comercio electrónico que comercializa sus productos a través de una plataforma digital y atiende a un volumen creciente de gente y transacciones. Para poder sobresalir en este mercado altamente competitivo, el manejo eficiente de los datos es vital, los datos de ventas e inventario permite optimizar la operación y planificar el abastecimiento, mientras que el análisis del comportamiento de los usuarios permite identificar tendencias, comprender sus intereses y detectar oportunidades para mejorar la experiencia de compra y aumentar la conversión.

2.2 Situación Actual (AS-IS) vs. Estado Deseado (TO-BE)

2.2.1 Situación AS-IS (Diagnóstico Actual y Puntos de Dolor)

En la actualidad, la organización cuenta con diferentes fuentes de datos. Los datos operacionales del negocio, como clientes, productos, ventas, entre otros, son almacenados en una base de datos transaccional. A su vez, las interacciones de los clientes con la plataforma generan grandes volúmenes de eventos y registros de comportamiento, como búsquedas, clics, filtros y visualizaciones de productos.

A pesar de contar con esta gran cantidad de información, la organización no la procesa y analiza aprovechando todo su potencial. En especial, los eventos generados por los usuarios no son aprovechados de manera sistemática para obtener información que apoye la toma de decisiones relevantes para el negocio. Esto representa una oportunidad desaprovechada para comprender mejor el comportamiento de los clientes, optimizar su experiencia en la plataforma, aumentar su permanencia y mejorar las estrategias orientadas a la conversión y, en consecuencia, al crecimiento de los ingresos del negocio.

2.2.2 Estado TO-BE (Visión de la Solución)

Un pipeline de ingeniería de datos que permita aprovechar las diferentes fuentes de datos generadas por la plataforma. Este contará con dos flujos de procesamiento diferenciados: un flujo batch orientado a los datos transaccionales e históricos y un flujo de streaming enfocado en la captura y procesamiento de aquellos eventos de interacción que requieren respuestas de baja latencia.

Este pipeline permitirá transformar los grandes volúmenes de datos generados por la organización en información útil para el análisis y la toma de decisiones. La empresa podrá contar con información analítica que relacione el comportamiento de los usuarios con los resultados del negocio. Esta información estará disponible para ser visualizada y analizada a través de herramientas de inteligencia de negocios, facilitando la identificación de patrones de comportamiento, tendencias y oportunidades de mejora en la experiencia del cliente y en los diferentes procesos comerciales.

2.3 Matriz de Stakeholders e Interesados del Proyecto

Stakeholder / Rol	Tipo de Perfil	Expectativa Principal	Valor Esperado / Uso del Producto de Datos
Gerente de Negocio	Negocio / Ejecutivo	Contar con información confiable y oportuna sobre el desempeño general del negocio, las ventas y el comportamiento de los usuarios.	Apoyar la toma de decisiones estratégicas, identificar tendencias de ventas y detectar oportunidades de mejorar la conversión y el crecimiento de los ingresos
Gerente de Marketing	Negocio / Comercial	Comprender el comportamiento de los usuarios dentro de la plataforma y evaluar el impacto de las estrategias de marketing.	Analizar patrones de navegación, productos de interés, interacciones y comportamiento de los clientes para optimizar campañas.
Analista de Datos	Técnico/Usuario Final	Acceder a información confiable y actualizada proveniente de los datos transaccionales y de interacción de usuarios.	Construcción de dashboards y reportes en Power BI, análisis de tendencias y generación de insights sobre ventas, productos y comportamiento de clientes.
Ingeniero de Datos	Técnico	Contar con pipelines de datos escalables, confiables y mantenibles para procesar los flujos en batch y streaming.	Facilitar el procesamiento y disponibilidad de los datos, el monitoreo de los pipelines.
Equipo de Operaciones/ Inventario	Operativo/Negocio	Obtener información sobre la demanda de los productos y el comportamiento de los clientes.	Mejorar la planificación del inventario, identificar productos con alta demanda y apoyar decisiones de abastecimiento.

3. Formulación del Problema de Ingeniería de Datos

3.1 Objetivo General del Proyecto

Diseñar, implementar y desplegar una arquitectura de ingeniería de datos multicloud y *Lakehouse* (combinando AWS, GCP y Azure/Power BI) que integre la ingesta escalable en tiempo real y *batch*, el almacenamiento optimizado bajo el formato Apache Iceberg y una capa de gobernanza transversal, con el fin de alimentar un motor de recomendaciones de productos y habilitar un tablero analítico para la toma de decisiones en un entorno de e-commerce.

3.2 Objetivos Específicos por Componente de la Trayectoria

3.2.1 Sistemas Intensivos en Datos (Big Data & DataOps)

Diseñar e implementar un pipeline híbrido para la ingesta de eventos de navegación en tiempo real mediante GCP Pub/Sub y datos transaccionales *batch* vía conexiones JDBC hacia AWS Glue (PySpark). La arquitectura debe desacoplar el procesamiento rápido (vía AWS Glue Streaming hacia Amazon DynamoDB) del procesamiento masivo, consolidando una capa *Lakehouse* inmutable sobre AWS S3 estructurada en formato Apache Iceberg (capas Bronze, Silver y Gold).

3.2.2 Bases de Datos Avanzadas

Modelar y optimizar las capas de almacenamiento analíticas y operacionales. Esto comprende el diseño de un modelo de clave-valor/documental en Amazon DynamoDB para servir perfiles de usuario en milisegundos, el particionamiento y ordenamiento de tablas Apache Iceberg en S3 para consultas analíticas masivas, y la optimización de planes de ejecución mediante BigQuery analizando estrategias de indexación, compresión (Parquet) y los compromisos del Teorema CAP entre los motores transaccionales y NoSQL.

3.2.3 Gestión y Gobernanza de Datos

Implementar un marco funcional de gobierno del dato guiado por DAMA-DMBOK. Se definirá un catálogo y diccionario de datos, el rastreo de linaje (*Data Lineage*) desde la ingesta en GCP hasta la visualización en Power BI, la automatización de pruebas de calidad de datos (completitud, unicidad y consistencia entre capas Bronze/Silver) y el enmascaramiento/hashing de datos de identificación personal (PII) en cumplimiento con normativas de protección de datos.

3.3 Preguntas de Negocio e Indicadores Clave de Desempeño (KPIs)

Pregunta de Negocio a Resolver	KPI / Indicador de Negocio	Métrica Técnica / SLA de Ingeniería	Componente Asociado

¿Cuáles son los productos recomendados para el usuario actual según su comportamiento reciente?	Tasa de Conversión de Recomendaciones (%) y Click-Through Rate (CTR).	Latencia de actualización en la capa de baja latencia (Pub/Sub ➔ DynamoDB) < 1 segundo.	Sistemas Intensivos en Datos
¿Cuál es el volumen de ventas, ticket promedio y tasa de abandono de carrito por categoría y día?	Ticket Promedio (AOV), Tasa de Abandono de Carrito y Ventas Totales por Período.	Tiempo de ejecución de consultas analíticas complejas en BigQuery < 2 segundos sobre la capa Gold.	Bases de Datos Avanzadas
¿Podemos garantizar que las decisiones de negocio se toman sobre datos confiables y legalmente protegidos?	*Score* de Calidad de Datos (*DQ Score*) y Cero Incidentes de Exposición de PII.	100% de campos PII (e.g., correos, nombres) anonimizados/hasheados en la capa Silver; Completitud $> 99\%$.	Gestión y Gobernanza de Datos

3.4 Alcance y Restricciones del Proyecto

- **Que SÍ incluye el proyecto:**
    - Despliegue de una arquitectura distribuida y multicloud que conecta GCP (Ingesta con Pub/Sub y almacenamiento con BigQuery), AWS (Procesamiento con Glue/Lambda, Almacenamiento S3 + Iceberg, NoSQL con DynamoDB, Motor SQL) y Azure / Power BI (Visualización).
    - Ingesta automatizada desde 2 fuentes heterogéneas: eventos en streaming de navegación web (clicks, carritos) y extracción *batch* vía JDBC desde la base de datos relacional del e-commerce.

- Implementación de una arquitectura Medallón (Bronze = datos crudos inmutables; Silver = datos limpios y deduplicados; Gold = datos agregados y modelos de asociación).
- Modelado analítico optimizado sobre el formato de tabla Apache Iceberg e integración NoSQL con DynamoDB.
- Catálogo de datos, documentación de linaje end-to-end, pruebas de calidad y políticas de anonimización de PII.
- Construcción de un Dashboard interactivo en Power BI conectado al motor analítico SQL.

- **Que NO incluye el proyecto:**

  - Entrenamiento y ajuste de modelos complejos de Machine Learning o Deep Learning (el motor de recomendación se basará en reglas de asociación y agregaciones algorítmicas/SQL como filtrado colaborativo simple).
  - Desarrollo del frontend o backend completo de la aplicación web del e-commerce (se utilizarán scripts simuladores de eventos de tráfico web y una base de datos con datos de muestra).
  - Despliegue de asistentes o agentes de Inteligencia Artificial Generativa.

- **Restricciones Técnicas, Organizacionales y Éticas:**

  - **Presupuesto Cloud:** El proyecto está estrictamente acotado a los créditos educativos y capas gratuitas de AWS, GCP y Azure. Para optimizar costos, se evitará la provisión de clusters permanentes (como EMR o Databricks) priorizando servicios serverless (AWS Glue Jobs por demanda y GCP Pub/Sub).

  - **Restricciones Técnicas:** Se debe garantizar la correcta interoperabilidad multicloud, gestionando roles y políticas de acceso de identidades (IAM) entre Google Cloud Platform y Amazon Web Services para permitir la lectura en S3 o la integración con BigQuery.

  - **Restricciones Éticas y Legales:** Los datos simulados de clientes (nombres, correos electrónicos, documentos de identidad) deberán enmascararse mediante algoritmos de hashing (SHA-256) en la transición de la capa Bronze a la Silver, cumpliendo con la Ley 1581 de 2012 de Colombia (Habeas Data) sobre protección de datos personales.

4. Metodología de Desarrollo y Cronograma

4.1 Marcos de referencia

- **CRISP-DM / TDSP:** Guiará las fases iniciales para entender las dinámicas de un e-commerce (eventos de tráfico vs. datos transaccionales), definir qué tipo de eventos son los que serán necesarios recolectar y estructurar el motor de recomendaciones a partir del flujo de interacción de los clientes.
- **DataOps:** Se aplicará para garantizar el ciclo de vida continuo de los pipelines, automatizando el flujo de datos entre GCP y AWS, controlando versiones de scripts en PySpark e infraestructura, y asegurando observabilidad en la ingesta en streaming y ejecuciones batch.

- **Agile / Scrum:** Estructurará el desarrollo del proyecto en iteraciones cortas (Sprints) con entregables incrementales y funcionales: desde la simulación de eventos hasta la integración multicloud y la visualización final.
- **DAMA-DMBOK:** Establecerá las políticas de gobernanza desde la arquitectura inicial, garantizando la calidad de los datos en las capas Bronze/Silver, la privacidad de información de clientes (PII) mediante *hashing*, y la documentación explícita del linaje multicloud.

4.2 Fases del Proyecto

Fase de la Metodología	Actividades Principales a Realizar	Marco / Disciplina Dominante
Fase 1. Problema y Dominio	**1.1** Levantamiento de requerimientos del e-commerce y motor de recomendaciones. **1.2** Definición de KPIs de negocio (AOV, CTR, Abandono de carrito) y SLAs técnicos. **1.3** Delimitación del alcance multicloud (AWS, GCP, Azure/Power BI) y restricciones de presupuesto. **1.4** Consolidación de la propuesta formal del proyecto.	CRISP-DM / Agile
Fase 2. Datos del Proyecto	**2.1** Identificación de fuentes: logs de eventos web y base de datos transaccional. **2.2** Desarrollo del script simulador de eventos de tráfico en tiempo real (clicks, compras entre otros). **2.3** Carga preliminar de la base de datos de productos/usuarios y aprovisionamiento del tópico en GCP Pub/Sub. **2.4** Profiling de datos: detección de nulos, inconsistencias de esquemas y tipos de datos en los eventos JSON.	Bases de Datos Avanzadas / CRISP-DM
Fase 3. Diseño de Arquitectura de datos	**3.1** Selección del patrón *Lakehouse* sobre la arquitectura Medallón. **3.2** Definición de servicios cloud: GCP Pub/Sub para ingesta, AWS S3/Glue/DynamoDB para almacenamiento y cómputo, BigQuery para SQL y Power BI para Inteligencia de negocio y graficado.	Sistemas Intensivos en Datos

	3.3 Diseño de flujos híbridos: *Path* rápido (Streaming a DynamoDB) y *Path* frío (Batch a S3 con Apache Iceberg).	
Fase 4. Modelado de Datos	**4.1** Modelo relacional transaccional (ER) para el catálogo de productos y usuarios. **4.2** Modelado *Lakehouse* analítico (Capa Gold) para métricas de e-commerce en S3/BigQuery. **4.3** Diseño NoSQL clave-valor en Amazon DynamoDB para almacenamiento de baja latencia de perfiles de usuario. **4.4** Configuración de estrategias de particionamiento por fecha/categoría en Apache Iceberg.	BD Avanzadas / Modelado
Fase 5. Ingeniería de Pipelines	**5.1** Configuración de la suscripción y conector de GCP Pub/Sub hacia AWS S3 (Capa Bronze). **5.2** Construcción de *AWS Glue Jobs* (PySpark) para procesamiento en tiempo real hacia DynamoDB. **5.3** Desarrollo de scripts PySpark en AWS Glue para procesamiento *batch* (limpieza Silver y agregación Gold). **5.4** Extracción JDBC desde la base de datos relacional hacia AWS Glue para cruce de datos maestros	DataOps / Big Data
Fase 6. Calidad y Gobernanza	**6.1** Creación del diccionario y catálogo de datos de las capas Bronze, Silver y Gold. **6.2** Mapeo del linaje de datos (*Data Lineage*) desde GCP Pub/Sub hasta Power BI pasando por S3 y BigQuery. **6.3** Implementación de reglas de validación de calidad de datos (completitud, formato JSON, tipos de datos). **6.4** Enmascaramiento y *hashing* (SHA-256) de datos sensibles (PII) en la capa Silver.	DAMA-DMBOK / Gestión

Fase 7. CI/CD y Despliegue	**7.1** Control de versiones del código de ingeniería en GitHub. **7.2** Creación de workflows (GitHub Actions) para el despliegue automático de jobs de AWS Glue y scripts de la capa de ingesta. **7.3** Pruebas integradas de conectividad entre plataformas (GCP ➔ AWS ➔ Azure/Power BI).	DataOps / DevOps
Fase 8. Observabilidad y Mejora	8.1 Configuración de tableros de monitoreo de pipelines 8.2 alertas de fallos 8.3 optimización de costos en la nube.	DataOps / Operación IT

5. Cronograma de Sprints, Entregables y Gestión de Riesgos

La ejecución del proyecto simulará un entorno de desarrollo ágil con 4 hitos de entrega críticos que coinciden con las evaluaciones del semestre.

5.1 Planificación de Entregas por Sprints

Sprint	Semanas de Ejecución	Fecha Clave de Entrega / Peso Evaluativo	Entregables e Hitos Principales del Sprint
Sprint 0	Semanas 1 a 3	29 de Julio (10%)	Documento de Propuesta de Proyecto, Canvas, Arquitectura Conceptual, definición de KPIs de negocio y Data Assessment preliminar.
Sprint 1	Semanas 4 a 7	26 de Agosto (30%)	Producto Alfa (Walking Skeleton): Infraestructura cloud aprovisionada, scripts de ingesta funcional (conexión a fuentes), almacenamiento en capa Raw, perfilamiento de datos y reglas de calidad básicas operando.
Sprint 2	Semanas 8 a 15	28 de Octubre (30%)	Producto Beta (Escalabilidad y Gobierno): Pipelines ETL/ELT complejos culminados, bases de datos optimizadas con índices/particiones, catálogo de datos poblado, rastreo de linaje activo y modelos analíticos expuestos en el Serving Layer.
Sprint Final	Semanas 16 a 17	11 de Noviembre (30%)	Producto Final (Operación y Consumo): Prácticas DataOps automatizadas (CI/CD fluyendo), monitoreo y alertas activas, Dashboard final consumiendo datos gobernados, Informe Técnico documentado y Sustentación Ejecutiva ante stakeholders.

5.2 Matriz Inicial de Riesgos del Proyecto

El equipo ha identificado los siguientes riesgos potenciales y sus estrategias de manejo:

Riesgo Identificado	Área de Impacto	Impacto / Prob.	Estrategia de Mitigación y Plan de Contingencia	Responsable de Mitigar
Agotamiento de créditos académicos o generación de costos inesperados en AWS, GCP o Power BI.	Infraestructura / Económico	Alto / Medio	Configurar presupuestos, cuotas y alertas de facturación en AWS y GCP. Usar servicios serverless y ejecución bajo demanda. Eliminar recursos temporales después de cada prueba. Como contingencia, reducir la frecuencia de procesamiento, trabajar con volúmenes controlados y ejecutar localmente los componentes no críticos.	Arquitecto Cloud
Fallas en la integración entre GCP Pub/Sub y los servicios de AWS.	Integración / Streaming	Alto / Medio	Desarrollar inicialmente una prueba de concepto con pocos eventos para validar autenticación, conectividad, formato y latencia. Implementar reintentos, confirmación de mensajes y una cola o almacenamiento temporal. Como contingencia, almacenar los eventos en archivos JSON y cargarlos a S3 mediante un proceso de micro-batch.	Ingeniero de pipelines
Inconsistencia entre los datos almacenados en DynamoDB y los datos consolidados en S3, Iceberg o BigQuery.	Datos / Consistencia	Alto / Medio	Definir a S3/Iceberg como fuente analítica de verdad y usar DynamoDB como capa de baja latencia. Ejecutar conciliaciones periódicas mediante conteos, sumatorias y fechas de actualización. Como contingencia, reconstruir los perfiles de DynamoDB a partir de la capa Silver o Gold.	Arquitecto de Datos
Mala calidad de datos detectada tardíamente:	Analítica / Calidad	Medio / Alto	Ejecutar perfilamiento desde el Sprint 1 e implementar pruebas automáticas de	Líder de Calidad y Gobernanza

nulos, fechas inválidas, identificadores duplicados o relaciones inexistentes.			completitud, unicidad, validez, consistencia e integridad referencial. Generar reportes de registros aceptados y rechazados. Como contingencia, impedir la promoción de datasets desde Bronze hacia Silver cuando no alcancen los umbrales definidos.	
Abandono de la materia o inasistencia reiterada de integrantes clave.	Gestión / Equipo	Alto / Bajo	Aplicación estricta del pacto pedagógico (Artículo 46 de la Universidad). Documentación exhaustiva en Git para que cualquier rol pueda ser asumido temporalmente por otro compañero.	Líder Técnico / Todo el equipo
Configuración incorrecta de IAM, cuentas de servicio, roles o credenciales entre las plataformas cloud.	Seguridad / Infraestructura	Alto / Medio	Aplicar el principio de mínimo privilegio, separar credenciales por ambiente y almacenar secretos mediante GitHub Secrets, AWS Secrets Manager o mecanismos equivalentes. Documentar las políticas utilizadas.	Arquitecto Cloud
Duplicación o pérdida de eventos durante la ingesta en streaming.	Datos / Calidad	Alto / Medio	Asignar un event_id único a cada evento, registrar fecha de generación y fecha de procesamiento, implementar operaciones idempotentes y deduplicación en Silver. Crear un repositorio para eventos rechazados.	Ingeniero de pipelines
Consultas lentas o costos elevados por particionamiento incorrecto en S3, Iceberg o BigQuery.	Rendimiento / Económico	Medio / Bajo	Particionar por atributos utilizados frecuentemente, como fecha y categoría, emplear Parquet, evitar archivos excesivamente pequeños y analizar los planes de ejecución. Como contingencia, crear tablas Gold agregadas y limitar las consultas de Power BI a los datos estrictamente necesarios.	Arquitecto de Datos

6. Criterios de Evaluación y Rúbrica de la Fase 1

Esta tabla presenta los criterios transparentes bajo los cuales el profesor evaluará y calificará el entregable de esta Propuesta de Proyecto (Sprint 0 - 10% del curso).

Criterio Evaluado	Ponderación	Sobresaliente (4.0 - 5.0)	Normal (3.0 - 4.0)	Insuficiente (0.0 - 2.9)
Claridad del Problema y Caso de Negocio	20%	Define con rigor el contexto del negocio, los problemas operativos (AS-IS) y presenta una matriz de stakeholders y preguntas de negocio con KPIs medibles y coherentes.	Define globalmente el problema de negocio, el AS-IS o TO-BE. Los stakeholders son muy forzados para un caso simulado, al igual que los KPI.	El problema es ambiguo, incompleto o está enfocado únicamente en aspectos tecnológicos sin conexión real con el valor del negocio.
Disponibilidad de datos transaccionales y analíticos para el proyecto	20%	Es claro completamente todas las fuentes de datos que usará para el proyecto para lograr un excelente proyecto, además está garantizada la calidad y cantidad de los datos.	No todas las fuentes de datos están disponibles y si bien definen que serán sinteticos no es clara su disponibilidad	El proyecto tiene alto riesgo por no disponibilidad de datos ni contar con la cantidad ni el volumen suficiente.
Integración de la Trayectoria Académica	20%	Demuestra una articulación clara, explícita y equilibrada de los objetivos en Sistemas Intensivos, BD Avanzadas y Gestión de Gobernanza de Datos.	No es claro ni explicito como integrará algunas de las materias, si bien de otras si.	No logra integrar las tres asignaturas obligatorias o ignora componentes vitales como la gobernanza, la optimización o el procesamiento distribuido.
Metodología y Planificación Estratégica	20%	Propone una adopción adaptada y clara	Propone un cronograma muy general	No define un marco de trabajo metodológico, o propone un

		de CRISP-DM, DataOps, Scrum y DAMA-DMBOK en sintonía con un cronograma y matriz de riesgos viables y realistas.	que resulta dificil evaluar su factibilidad técnica y en el tiempo.	cronograma desfasado con los Sprints reales del semestre de la Universidad.
Calidad Técnica del Documento y Formato	20%	El documento muestra redacción profesional, estructuración rigurosa de tablas, manejo de referencias que sustentan todo el proyecto, cumplimiento total de las pautas y presentación impecable.	El documento no presenta algunas partes importantes, que da a entender falta de rigurosidad en algunos aspectos.	Entrega un documento incompleto, descuidado en su formato, con mala ortografía o que omite secciones clave de las instrucciones dadas.

7. Diagrama de Arquitectura

